Universidad del Valle de Guatemala

CC2017 – Deep Learning

Clasificación de señales de tránsito mediante redes neuronales convolucionales

Comparación entre una CNN entrenada desde cero y MobileNetV2

María José Girón – 23559
Leonardo Mejía – 23648
Milton Polanco – 23471
Dilary Cruz – 231010

Octubre de 2026

Índice

1. Descripción del problema **1**

2. Análisis del conjunto de datos **1**

3. Propuesta de solución **2**

4. Descripción de la solución **3**

4.1. CNN desde cero 3

4.2. Transfer learning con MobileNetV2 3

4.3. Inferencia y aplicación 4

5. Herramientas aplicadas **4**

5.1. Uso de herramientas de asistencia generativa 4

6. Resultados **5**

6.1. Comparación global 5

6.2. Análisis de errores 5

6.3. Robustez 6

6.4. Explicabilidad con Grad-CAM 6

7. Limitaciones **7**

8. Conclusiones **7**

Video de demostración **8**

Reproducibilidad **8**

Índice de figuras

1. Cantidad de imágenes por clase en el conjunto de entrenamiento. 2

2. Ejemplo de cada una de las 43 clases de GTSRB. 2

3. Pérdida y exactitud durante el entrenamiento de la CNN. 3

4. Comparación de las etapas de transferencia y ajuste fino. 4

5. Matrices de confusión normalizadas por clase. 5

6. Degradación de accuracy conforme aumenta la severidad. 6

7. Grad-CAM en tres aciertos (fila superior) y tres errores (fila inferior). 7

Índice de cuadros

1. Resultados sobre el test oficial de GTSRB. 5
2. Accuracy de la CNN por perturbación y severidad. 6

Resumen

Este trabajo estudia la clasificación automática de señales de tránsito mediante aprendizaje profundo. Se comparó una red convolucional compacta entrenada desde cero con MobileNetV2 preentrenada en ImageNet, tanto con el extractor de características congelado como mediante ajuste fino. Los experimentos emplearon las 43 clases del conjunto German Traffic Sign Recognition Benchmark (GTSRB), con una separación de entrenamiento y validación agrupada por secuencia de captura para evitar fuga de datos. La CNN propia obtuvo 99.18 % de exactitud y 98.70 % de F1 macro en el test oficial, mientras que MobileNetV2 alcanzó 59.91 % con el backbone congelado y 76.76 % después del ajuste fino. También se evaluó la robustez ante oscurecimiento, ruido gaussiano y desenfoque, y se utilizaron mapas Grad-CAM para analizar las regiones relevantes. Los resultados muestran que la arquitectura compacta especializada supera a los modelos transferidos en este dominio y que el desenfoque intenso constituye su principal debilidad.

1. Descripción del problema

El reconocimiento de señales de tránsito es un componente de los sistemas avanzados de asistencia al conductor y de la percepción para vehículos autónomos. Un clasificador debe distinguir señales con diferencias sutiles, como los distintos límites de velocidad, bajo variaciones de escala, iluminación, enfoque y perspectiva. Los errores pueden producirse entre clases visualmente parecidas aun cuando el objeto general haya sido localizado correctamente.

El objetivo del proyecto es construir y evaluar un sistema capaz de asignar una imagen a una de las 43 clases de GTSRB. Además de medir exactitud, se busca responder cuatro preguntas: (1) si una CNN compacta puede aprender el dominio desde cero; (2) si las características aprendidas en ImageNet se transfieren a señales de baja resolución; (3) qué clases y condiciones producen los errores principales; y (4) qué regiones de la imagen sustentan una predicción.

2. Análisis del conjunto de datos

GTSRB contiene 39,209 imágenes de entrenamiento y 12,630 imágenes de test distribuidas en 43 clases [1]. Las imágenes de entrenamiento tienen anchos entre 25 y 243 píxeles y alturas entre 25 y 225 píxeles. La clase menos frecuente contiene 210 observaciones y la más frecuente 2,250, una razón de 10.7 a 1. Esta variación justifica reportar F1 macro, que otorga igual peso a cada clase, junto con exactitud y métricas ponderadas.

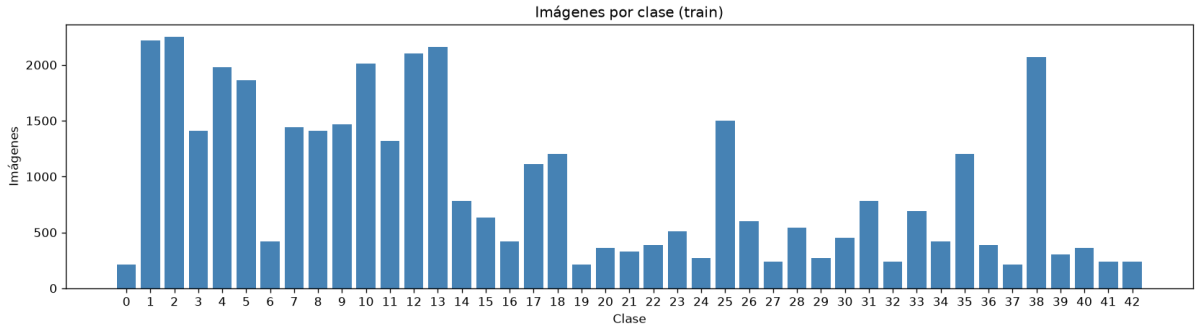


Figura 1: Cantidad de imágenes por clase en el conjunto de entrenamiento.

Cada señal física fue fotografiada en una secuencia o *track* mientras el vehículo se aproximaba. Las imágenes consecutivas son casi idénticas; una división aleatoria por imagen colocaría ejemplos del mismo objeto en entrenamiento y validación. Para evitar una estimación optimista, los 1,307 tracks se dividieron de forma estratificada: 33,299 imágenes para entrenamiento y 5,910 para validación, sin tracks compartidos. El test oficial se reservó para la comparación final.

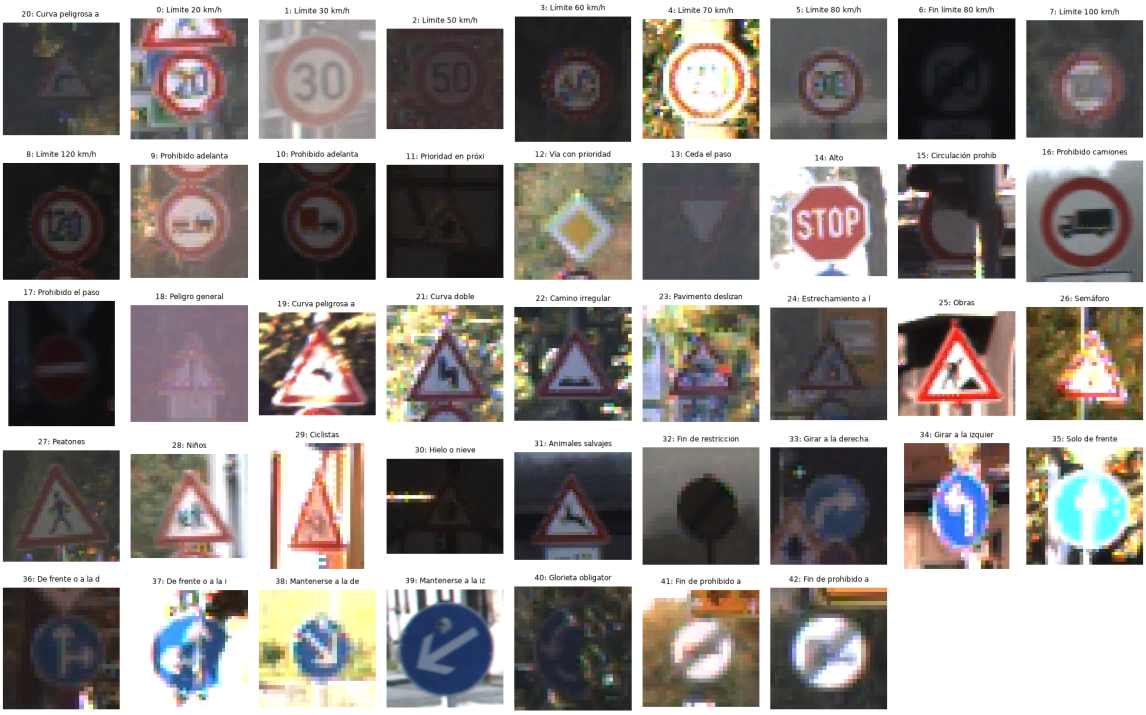


Figura 2: Ejemplo de cada una de las 43 clases de GTSRB.

3. Propuesta de solución

Se propuso comparar una arquitectura especializada y compacta con un modelo preentrenado de uso general. La CNN propia procesa imágenes de 48×48 píxeles. MobileNetV2 utiliza entradas de 96×96 para reducir el costo en CPU, manteniendo la normalización de ImageNet. En ambos

casos se aplican rotaciones pequeñas, traslación, cambios de escala, brillo, contraste y saturación durante entrenamiento. No se utiliza reflexión horizontal porque alteraría el significado de señales direccionales.

El flujo completo comprende descarga y validación de datos, entrenamiento, selección mediante pérdida de validación, evaluación en el test oficial, análisis de errores, robustez, explicabilidad e inferencia interactiva. Todos los experimentos usan semilla 42 y conservan los pesos de la mejor època mediante *early stopping*.

4. Descripción de la solución

4.1. CNN desde cero

La red propia contiene tres bloques convolucionales con 32, 64 y 128 canales. Cada bloque aplica dos secuencias convolución–BatchNorm–ReLU, seguidas por max pooling y dropout espacial. Un pooling promedio global transforma los mapas finales en un vector de 128 componentes. El clasificador contiene una capa de 256 unidades, ReLU, dropout y una salida de 43 logits. La arquitectura tiene 331,531 parámetros entrenables.

El entrenamiento usa Adam con tasa inicial 10^{-3}, reducción de tasa ante estancamiento y paciencia de cinco èpocas. La ejecución terminó por early stopping en la època 26; la menor pérdida de validación se obtuvo en la època 21.

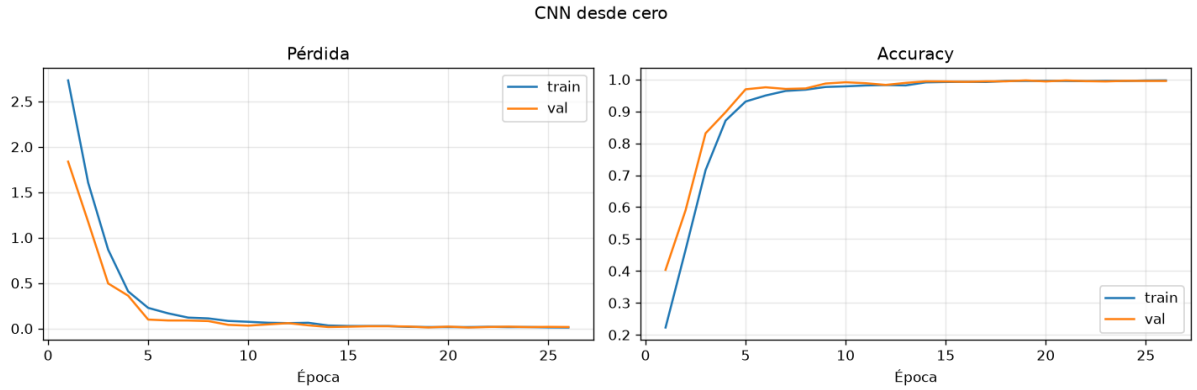


Figura 3: Pérdida y exactitud durante el entrenamiento de la CNN.

4.2. Transfer learning con MobileNetV2

MobileNetV2 emplea convoluciones separables en profundidad y bloques residuales invertidos [2]. En la etapa A se sustituyó el clasificador y se congeló el extractor preentrenado; solamente 55,083 parámetros (2.4 %) quedaron entrenables. En la etapa B se descongelaron los ùltimos cuatro bloques y se usaron tasas de 10^{-4} para el backbone y 10^{-3} para el clasificador. Esta configuración elevó el número de parámetros entrenables a 1,581,163 (69.4 %).

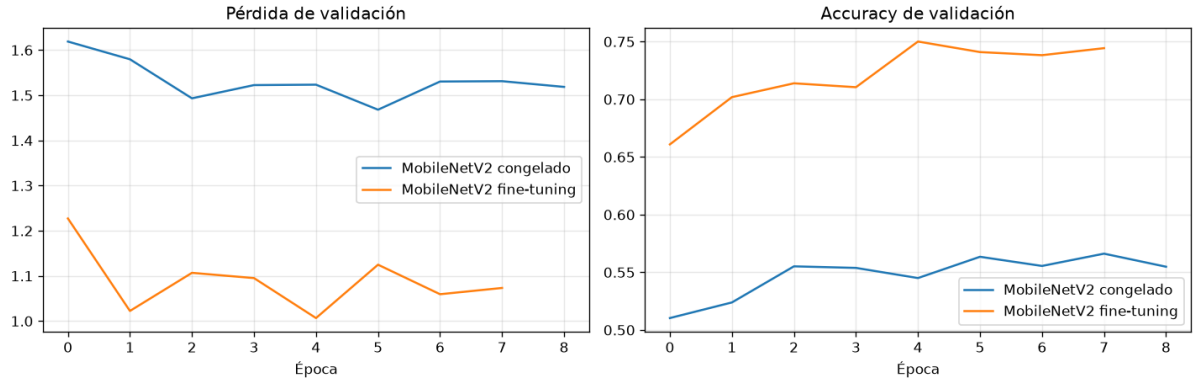


Figura 4: Comparación de las etapas de transferencia y ajuste fino.

4.3. Inferencia y aplicación

La lógica de inferencia se separó de los notebooks en un módulo que carga el checkpoint, reproduce la transformación de evaluación y devuelve las cinco clases de mayor probabilidad. La interfaz Gradio permite cargar una imagen, consultar las probabilidades y visualizar la explicación Grad-CAM. El sistema se ejecuta localmente en CPU y no necesita acceso a servicios externos una vez instaladas las dependencias y descargado el modelo.

5. Herramientas aplicadas

La implementación utiliza Python, PyTorch y torchvision para modelos y entrenamiento; pandas y NumPy para manipulación de datos; scikit-learn para métricas; Pillow y OpenCV para imágenes; Matplotlib y seaborn para visualización; kagglehub para obtener el conjunto de datos; y Gradio para la demostración interactiva. Los notebooks documentan las decisiones experimentales y los módulos de `src/` concentran la lógica reutilizable.

5.1. Uso de herramientas de asistencia generativa

Se utilizó asistencia generativa durante la planificación, revisión del enunciado, depuración del entorno y estructuración de módulos. Sus respuestas se trataron como propuestas sujetas a verificación: los modelos fueron entrenados localmente, las métricas se recalcularon sobre el test oficial, las funciones nuevas cuentan con pruebas y las figuras se inspeccionaron antes de incorporarlas. El historial resumido de solicitudes, resultados, errores y decisiones se conserva en `docs/prompts_ia.md`. Entre los problemas identificados estuvieron dependencias ausentes, restricciones temporales de red y el manejo de procesos de carga en Windows. Esta revisión permitió distinguir errores de entorno de errores del modelo y mantener trazabilidad sobre la evolución de la solución.

6. Resultados

6.1. Comparación global

La Tabla 1 resume la evaluación de las 12,630 imágenes del test oficial. La CNN supera a MobileNetV2 ajustada por 22.42 puntos porcentuales de exactitud y a la versión congelada por 39.27 puntos. La cercanía entre F1 macro y ponderado de la CNN muestra que el desempeño no se concentra solamente en las clases frecuentes.

Cuadro 1: Resultados sobre el test oficial de GTSRB.

Modelo	Accuracy	F1 macro	F1 ponderado	ms/imagen
CNN desde cero	**0.9918**	**0.9870**	**0.9919**	7.41
MobileNetV2 congelada	0.5991	0.5164	0.5962	**3.09**
MobileNetV2 fine-tuning	0.7676	0.7102	0.7668	3.62

El resultado ilustra que transfer learning no garantiza una mejora. ImageNet contiene fotografías naturales a mayor resolución, mientras que GTSRB contiene objetos pequeños, centrados y con patrones geométricos específicos. El ajuste fino mejora MobileNetV2 en 16.85 puntos de exactitud, pero la arquitectura especializada sigue siendo superior.

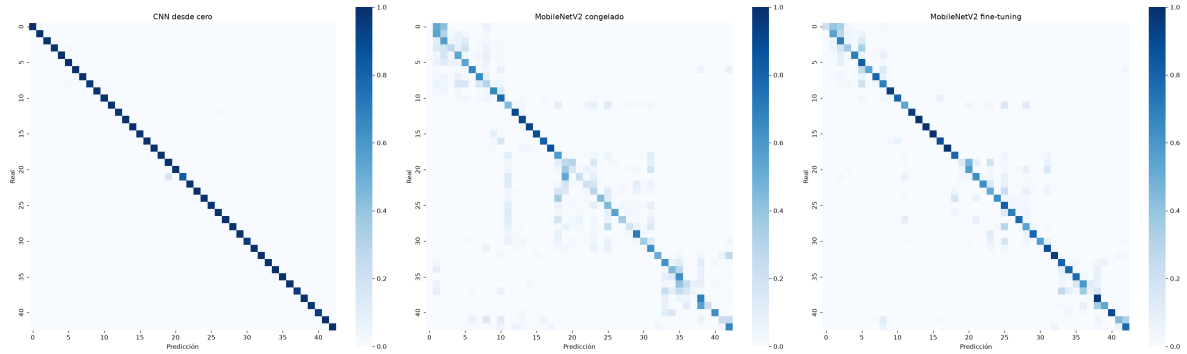


Figura 5: Matrices de confusión normalizadas por clase.

6.2. Análisis de errores

La CNN comete pocos errores. Los pares más frecuentes incluyen curva doble confundida con curva peligrosa a la izquierda (14 casos), vía con prioridad confundida con semáforo (14 casos) y límite de 120 km/h confundido con 80 km/h (9 casos). MobileNetV2 concentra muchos errores en límites de velocidad: por ejemplo, la versión ajustada confunde 209 imágenes de 30 km/h con 50 km/h y 157 imágenes de 60 km/h con 80 km/h. Estas clases comparten forma circular, borde rojo y dígitos que pueden perder detalle al reducir la resolución.

6.3. Robustez

La CNN seleccionada se evaluó sin reentrenamiento bajo tres perturbaciones y tres severidades. El brillo se multiplicó por 0.78, 0.56 y 0.34; el ruido gaussiano utilizó desviaciones estándar de 0.045, 0.090 y 0.135 sobre intensidades normalizadas; y el desenfoque gaussiano usó radios de 0.8, 1.6 y 2.4 píxeles.

Cuadro 2: Accuracy de la CNN por perturbación y severidad.

Condición	Nivel 0	Nivel 1	Nivel 2	Nivel 3
Brillo reducido	0.9918	0.9914	0.9872	0.9815
Ruido gaussiano	0.9918	0.9569	0.8359	0.7188
Desenfoque gaussiano	0.9918	0.9816	0.8344	0.5574

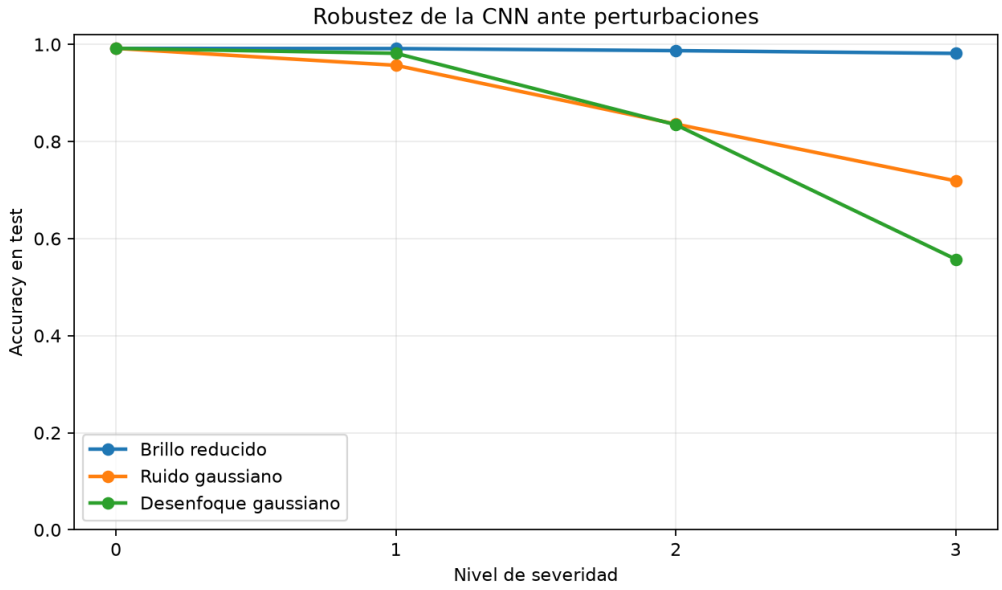


Figura 6: Degradación de accuracy conforme aumenta la severidad.

El oscurecimiento tiene un efecto limitado: incluso en el nivel 3 la exactitud permanece en 98.15 %. El ruido y el desenfoque producen degradaciones no lineales. El desenfoque severo reduce la exactitud a 55.74 %, el peor resultado observado, porque elimina bordes y dígitos esenciales para separar clases similares. Este resultado sugiere que una versión futura debe incluir desenfoque y ruido en el aumento de datos.

6.4. Explicabilidad con Grad-CAM

Grad-CAM pondera los mapas de activación de la ùltima capa convolucional mediante los gradientes de la clase seleccionada [3]. Los mapas muestran que en los aciertos la red concentra su respuesta en el interior de la señal y en sus símbolos. En los errores también localiza la señal, pero

atiende regiones degradadas o insuficientes para distinguir detalles de clase. Por tanto, la mayor parte de los fallos analizados corresponde a clasificación fina y no a una atención completamente desviada hacia el fondo.

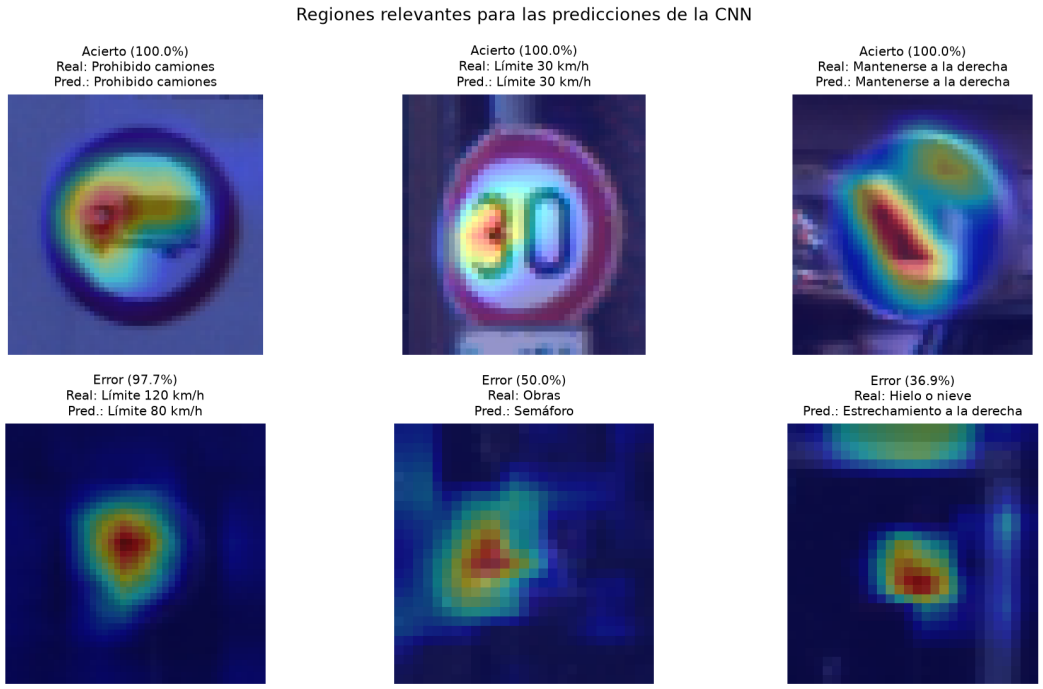


Figura 7: Grad-CAM en tres aciertos (fila superior) y tres errores (fila inferior).

7. Limitaciones

Los tiempos se midieron en CPU y dependen del equipo, tamaño de lote y sistema de entrada/salida. MobileNetV2 se evaluó a 96×96 y no a la resolución habitual de ImageNet, lo que reduce costo pero puede limitar la transferencia. La robustez considera perturbaciones sintéticas aisladas; no representa todas las combinaciones de clima, movimiento, oclusión y perspectiva del mundo real. Grad-CAM ofrece una explicación espacial aproximada y no demuestra causalidad. Finalmente, GTSRB corresponde a señales alemanas y no cubre todas las variantes regionales.

8. Conclusiones

La CNN compacta entrenada desde cero fue la mejor alternativa para GTSRB: alcanzó 99.18 % de exactitud y 98.70 % de F1 macro, con un costo de 7.41 ms por imagen en CPU. MobileNetV2 mejoró sustancialmente mediante fine-tuning, pero sus características preentrenadas no igualaron a la arquitectura especializada. La separación por tracks, el uso de métricas macro y el test oficial permiten sostener que el resultado no depende de fuga entre secuencias ni solamente de clases frecuentes.

El análisis de robustez identificó el desenfoque como la principal debilidad: la exactitud cae

a 55.74 % en la severidad máxima, mientras que el oscurecimiento severo conserva 98.15 %. Grad-CAM confirma que la red suele atender la región de la señal incluso cuando se equivoca. Como continuación se propone entrenar con ruido y desenfoque, calibrar las probabilidades, evaluar imágenes locales y ampliar el conjunto con señales de otras regiones.

Video de demostración

El video muestra la aplicación Gradio clasificando señales en vivo con su explicación Grad-CAM, describe brevemente la implementación y resume los hallazgos principales. Está disponible en: `https://youtu.be/QKezHRry-co`

Reproducibilidad

Repositorio público: `https://github.com/tismajo/CC2017-ProyectoFinal`

El repositorio contiene los módulos de datos, modelos, entrenamiento, métricas, inferencia, robustez y Grad-CAM; notebooks ejecutados; scripts para regenerar figuras; pruebas automatizadas; y la aplicación Gradio. El archivo `requirements.txt` enumera las dependencias. El dataset se almacena en la caché de kagglehub y no se duplica en el repositorio.

Referencias

[1] J. Stallkamp, M. Schlipsing, J. Salmen y C. Igel, "Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition", *Neural Networks*, vol. 32, pp. 323–332, 2012.

[2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov y L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks", *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 4510–4520, 2018.

[3] R. R. Selvaraju et al., "Grad-CAM: Visual explanations from deep networks via gradient-based localization", *Proceedings of the IEEE International Conference on Computer Vision*, pp. 618–626, 2017.

[4] A. Paszke et al., "PyTorch: An imperative style, high-performance deep learning library", *Advances in Neural Information Processing Systems*, vol. 32, 2019.