Universidad del Valle de Guatemala
CC2017 - Deep Learning

Clasificacion de senales de transito mediante redes neuronales convolucionales

Comparacion entre una CNN entrenada desde cero y MobileNetV2

María José Girón - 23559
Leonardo Mejía - 23648
Milton Polanco - 23471

Octubre de 2026

Contenido

Resumen 3

1. Descripcion del problema 3

2. Analisis del conjunto de datos 3

3. Propuesta de solucion 4

4. Descripcion de la solucion 4

4.1 CNN desde cero 4

4.2 Transfer learning 5

4.3 Inferencia e interfaz 5

5. Herramientas aplicadas 5

5.1 Asistencia generativa 5

6. Resultados 6

6.1 Comparacion global 6

6.2 Analisis de errores 6

6.3 Robustez 6

6.4 Explicabilidad 7

7. Limitaciones 8

8. Conclusiones 8

Referencias 8

Resumen

Este trabajo estudia la clasificacion automatica de senales de transito mediante aprendizaje profundo. Se comparo una red convolucional compacta entrenada desde cero con MobileNetV2 preentrenada en ImageNet, tanto con el extractor congelado como mediante ajuste fino. Los experimentos emplearon las 43 clases de GTSRB y una separacion por secuencia de captura para evitar fuga de datos. La CNN obtuvo 99.18% de accuracy y 98.70% de F1 macro en el test oficial; MobileNetV2 obtuvo 59.91% con el backbone congelado y 76.76% despues del ajuste fino. La evaluacion de robustez identifico el desenfoque intenso como la principal debilidad.

1. Descripcion del problema

El reconocimiento de senales de transito es un componente de los sistemas de asistencia al conductor y de percepcion vehicular. El clasificador debe separar clases con diferencias sutiles bajo variaciones de escala, iluminacion, enfoque y perspectiva. El objetivo es asignar cada imagen a una de 43 clases y analizar no solo la exactitud, sino tambien transferencia, errores, robustez y regiones relevantes para la prediccion.

2. Analisis del conjunto de datos

GTSRB contiene 39,209 imagenes de entrenamiento y 12,630 de test. Las imagenes varian entre 25 y 243 pixeles de ancho y entre 25 y 225 de alto. La clase menos frecuente contiene 210 ejemplos y la mas frecuente 2,250, una razon de 10.7 a 1. Por ello se reporta F1 macro junto con accuracy y metricas ponderadas.

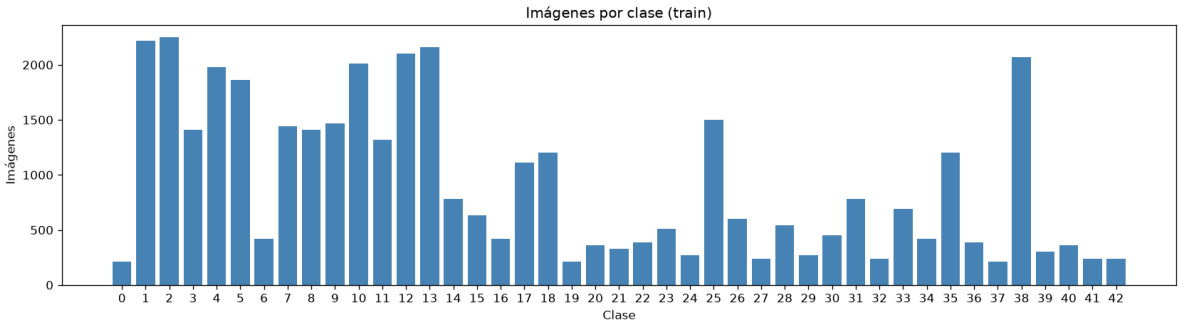


Figura 1. Cantidad de imagenes por clase en entrenamiento.

Las fotografias consecutivas de una misma senal forman tracks casi identicos. Los 1,307 tracks se dividieron de manera estratificada en 33,299 imagenes de entrenamiento y 5,910 de validacion, sin tracks compartidos. El test oficial se reservo para la comparacion final.

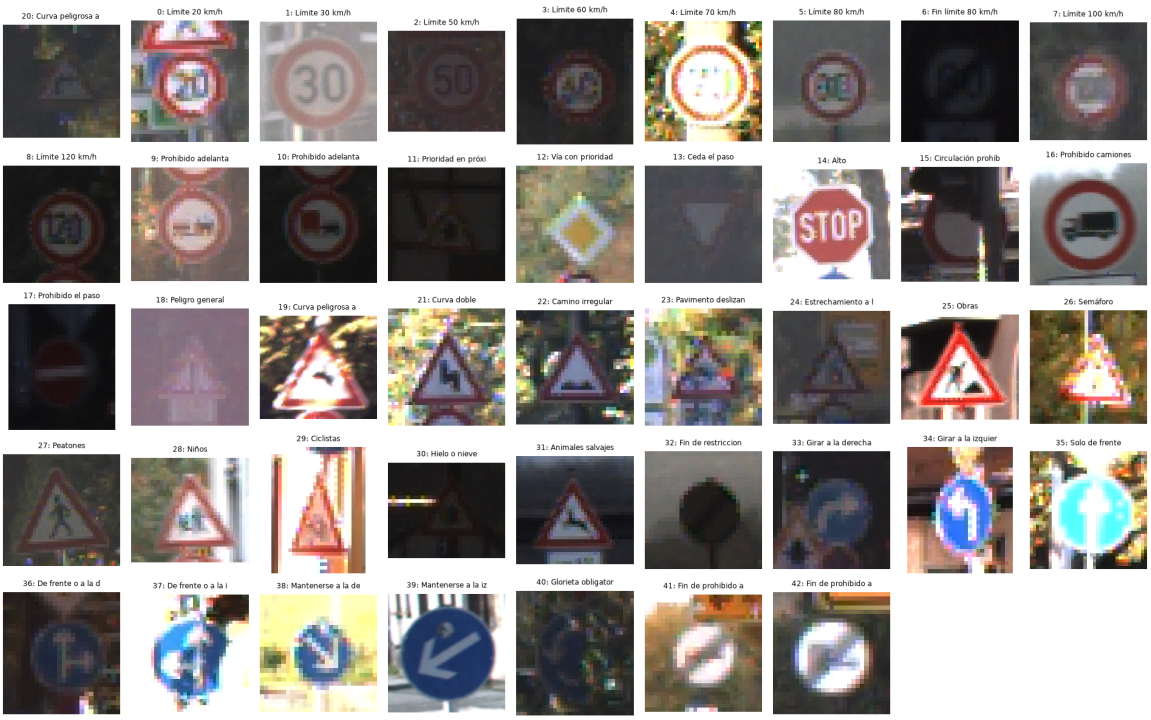


Figura 2. Ejemplo de cada clase de GTSRB.

3. Propuesta de solucion

Se comparo una CNN especializada con MobileNetV2. La CNN procesa entradas de 48 x 48 y el modelo transferido entradas de 96 x 96 normalizadas como ImageNet. El aumento de datos incluye pequenas rotaciones, traslacion, escala y cambios fotometricos. No se usa reflexion horizontal porque alteraria el significado de senales direccionales.

4. Descripcion de la solucion

4.1 CNN desde cero

La CNN contiene tres bloques con 32, 64 y 128 canales. Cada bloque aplica dos secuencias convolucion-BatchNorm-ReLU, max pooling y dropout espacial. Un pooling promedio global alimenta un clasificador de 256 unidades y 43 salidas. La arquitectura tiene 331,531 parametros entrenables. Se uso Adam, reduccion de tasa y early stopping; el proceso termino en la epoca 26 y la menor perdida de validacion se obtuvo en la epoca 21.

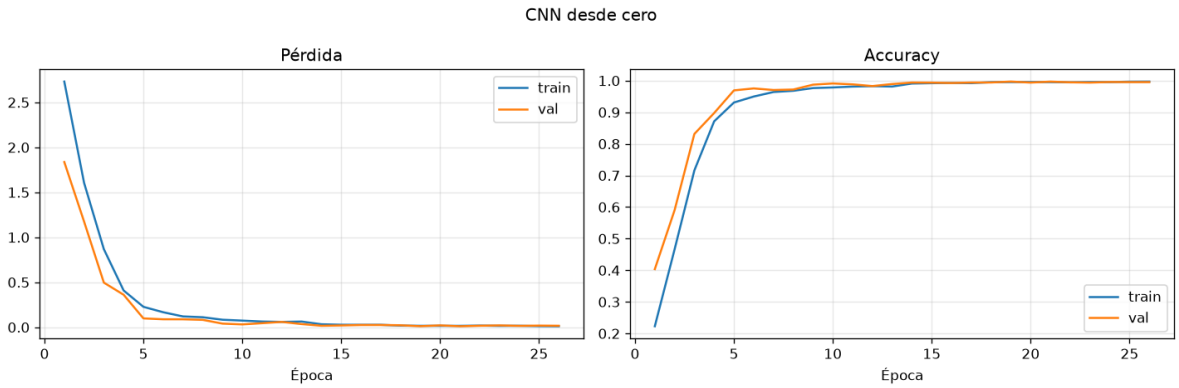


Figura 3. Curvas de entrenamiento y validacion de la CNN.

4.2 Transfer learning

En la primera etapa de MobileNetV2 se entrenaron 55,083 parametros (2.4%). En el ajuste fino se descongelaron los ultimos cuatro bloques, para un total de 1,581,163 parametros entrenables (69.4%). El backbone uso una tasa de 1e-4 y el clasificador 1e-3.

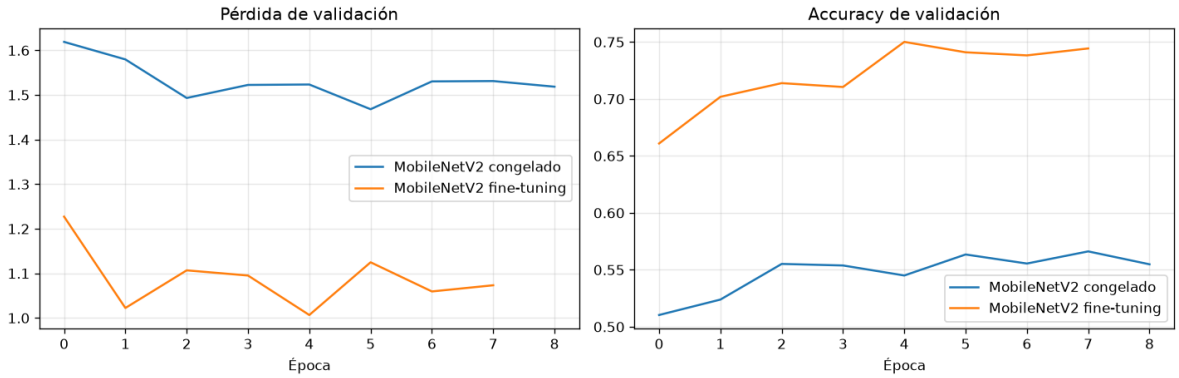


Figura 4. Comparacion de MobileNetV2 congelada y ajustada.

4.3 Inferencia e interfaz

La inferencia se separo de los notebooks en un modulo que carga el checkpoint, reproduce el preprocesamiento y devuelve las cinco clases mas probables. La interfaz Gradio permite cargar una imagen y visualizar las probabilidades junto con un mapa Grad-CAM.

5. Herramientas aplicadas

La implementacion utiliza Python, PyTorch, torchvision, pandas, NumPy, scikit-learn, Pillow, OpenCV, Matplotlib, seaborn, kagglehub y Gradio. Los notebooks documentan los experimentos y los modulos de src concentran la logica reutilizable.

5.1 Asistencia generativa

Se utilizo asistencia generativa durante planificacion, revision del enunciado, depuracion e integracion. Las propuestas se validaron mediante entrenamiento local, recalculo de metricas, pruebas automatizadas e inspeccion de figuras. El registro de solicitudes, resultados y errores se conserva en docs/prompts_ia.md, conforme al requisito de trazabilidad del proyecto.

6. Resultados

6.1 Comparacion global

La CNN supera a MobileNetV2 ajustada por 22.42 puntos de accuracy y a la version congelada por 39.27. La cercania entre F1 macro y ponderado en la CNN indica un desempeno equilibrado entre clases frecuentes y minoritarias.

Modelo	Accuracy	F1 macro	F1 ponderado	ms/imagen
CNN desde cero	0.9918	0.9870	0.9919	7.41
MobileNetV2 congelada	0.5991	0.5164	0.5962	3.09
MobileNetV2 fine-tuning	0.7676	0.7102	0.7668	3.62

Tabla 1. Resultados sobre el test oficial.

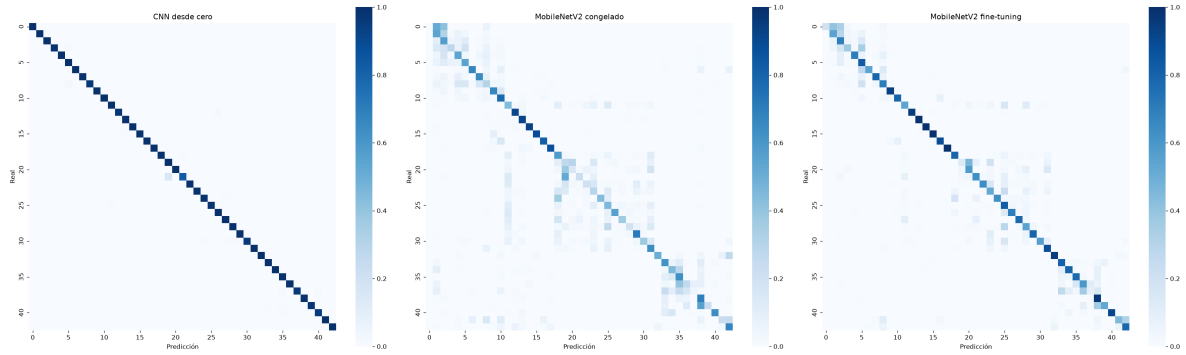


Figura 5. Matrices de confusion normalizadas.

6.2 Analisis de errores

Los errores de la CNN incluyen curva doble frente a curva peligrosa a la izquierda, via con prioridad frente a semaforo y limites de 120 frente a 80 km/h. MobileNetV2 concentra errores en limites de velocidad que comparten forma circular, borde rojo y digitos de bajo contraste.

6.3 Robustez

La CNN se evaluo sin reentrenamiento bajo tres niveles de brillo reducido, ruido gaussiano y desenfoque. Cada condicion se aplico a las 12,630 imagenes del test oficial.

Condicion	Nivel 0	Nivel 1	Nivel 2	Nivel 3
Brillo reducido	0.9918	0.9914	0.9872	0.9815
Ruido gaussiano	0.9918	0.9569	0.8359	0.7188
Desenfoque	0.9918	0.9816	0.8344	0.5574

Tabla 2. Accuracy por perturbacion y severidad.

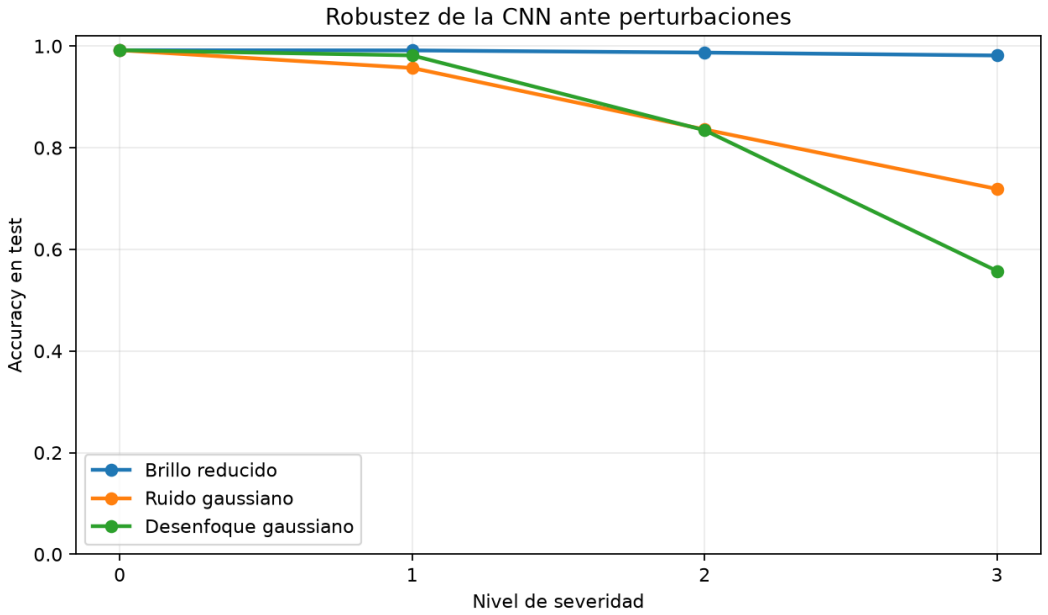


Figura 6. Degradacion de accuracy por severidad.

El brillo tiene poco efecto: en el nivel 3 la accuracy permanece en 98.15%. El ruido severo la reduce a 71.88% y el desenfoque severo a 55.74%. El desenfoque elimina bordes y digitos necesarios para separar clases similares y constituye la principal debilidad observada.

6.4 Explicabilidad

Grad-CAM pondera los mapas de la ultima capa convolucional mediante gradientes de la clase. En los aciertos la red concentra su respuesta en simbolos internos. En los errores suele localizar la senal, pero atiende detalles degradados o insuficientes para separar clases visualmente cercanas.

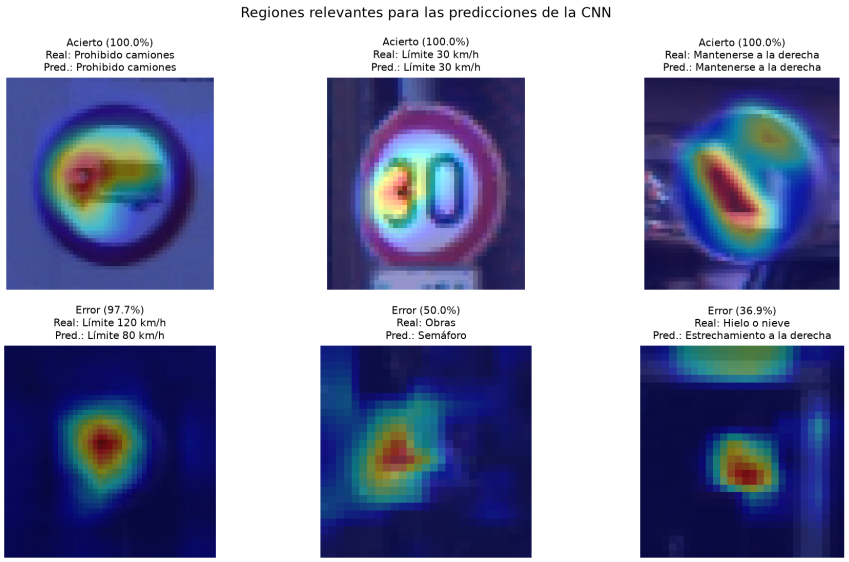


Figura 7. Grad-CAM en tres aciertos y tres errores.

7. Limitaciones

Los tiempos se midieron en CPU y dependen del equipo. MobileNetV2 se evaluo a 96 x 96, no a la resolucion habitual de ImageNet. Las perturbaciones son sinteticas y aisladas, y Grad-CAM ofrece una explicacion espacial aproximada, no una prueba causal. GTSRB tampoco cubre todas las variantes regionales de senales.

8. Conclusiones

La CNN compacta fue la mejor alternativa: alcanzo 99.18% de accuracy y 98.70% de F1 macro con 7.41 ms por imagen en CPU. MobileNetV2 mejoro con fine-tuning, pero no igualo la arquitectura especializada. La separacion por tracks y el test oficial respaldan la validez de la comparacion.

La robustez mostro que el oscurecimiento tiene impacto limitado, mientras que el desenfoque es la debilidad principal. Como trabajo futuro se propone entrenar con ruido y blur, calibrar las probabilidades y evaluar imagenes locales y senales de otras regiones.

Referencias

[1] J. Stallkamp, M. Schlipsing, J. Salmen y C. Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. Neural Networks, 32:323-332, 2012.

[2] M. Sandler et al. MobileNetV2: Inverted residuals and linear bottlenecks. CVPR, 2018.

[3] R. R. Selvaraju et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization. ICCV, 2017.

[4] A. Paszke et al. PyTorch: An imperative style, high-performance deep learning library. NeurIPS, 2019.